



## 从拉普拉斯矩阵说到谱聚类

2014年11月03日 11:33:37 v\_JULY\_v 阅读数: 70667 更多



41



24



# 从拉普拉斯矩阵说到谱聚类

## 0 引言

11月1日上午, 机器学习班 第7次课, 邹讲聚类 (PPT), 其中的谱聚类引起了自己的兴趣, 邹从最基本的概念: 单位向量、两个向量的正交、方阵征向量, 讲到相似度图、拉普拉斯矩阵, 最后讲谱聚类的目标函数和其算法流程。

课后自己又琢磨了番谱聚类跟拉普拉斯矩阵, 打算写篇博客记录学习心得, 若有不足或建议, 欢迎随时不吝指出, thanks。

## 1 矩阵基础

在讲谱聚类之前, 有必要了解一些矩阵方面的基础知识。

### 1.0 理解矩阵的12点数学笔记

如果对矩阵的概念已经模糊, 推荐国内一人写的《理解矩阵by孟岩》系列, 其中, 抛出了很多有趣的观点, 我之前在阅读的过程中做了些笔记, 如

“1、简而言之: 矩阵是线性空间里的变换的描述, 相似矩阵则是对同一个线性变换的不同描述。那, 何谓空间? 本质而言, “空间是容纳运动的一个: 变换则规定了对应空间的运动” by孟岩。在线性空间选定基后, 向量刻画对象的运动, 运动则通过矩阵与向量相乘来施加。然, 到底什么是基? 坐标系

2、有了基, 那么在(1)中所言的则应是: 矩阵是线性空间里的变换的描述, 相似矩阵则是对同一个线性变换在不同基(坐标系)下的不同描述。出来了两个问题, 一者何谓基(坐标系)如何理解? 事实上, 所谓变换, 即空间里从一个点(元素/对象)到另一个(元素/对象)的跃迁, 矩阵用来描述线性变换。基呢?通过前面已知, 矩阵无非不过线性空间中的线性变换的一个东西而已, 线性变换为名词, 矩阵为描述它的形容词, 正如描述同一个人长得好看可以用多个不同形容词“帅”“靓”描述, 同一个线性变换也可以由阵来描述, 而由哪一个矩阵描述它, 则由基(坐标系)确定。

3、前面说了基, 坐标系也, 形象表述则为角度, 看一个问题的角度不同, 描述问题得到的结论也不同, 但结论不代表问题本身, 同理, 对于一个线性变换, 可以选定一组基阵描述它, 换一组基, 得到不同矩阵描述它, 矩阵只是描述线性变换非线性变换本身, 类比给一个人选取不同角度拍照。

4、前面都是说矩阵描述线性变换, 然, 矩阵不仅可以用来描述线性变换, 更可以用来描述基(坐标系/角度), 前者好理解, 无非是通过变换的矩阵把线性空间中的一个点上去, 但你说矩阵用来描述基(把一个坐标系变换到另一个坐标系), 这可又是何意呢? 实际上, 变换点与变换坐标系, 异曲同工!

(@坎儿井围脖: 矩阵还可以用来描述微分和积分变换。关键看基代表什么, 用坐标基就是坐标变换。如果基是小波基或傅里叶基, 就可以用来描述小波变换或傅里叶变

5、矩阵是线性运动(变换)的描述, 矩阵与向量相乘则是实施运动(变换)的过程, 同一个变换在不同的坐标系下表现为不同的矩阵, 但本质/征值相同, 运动是相对的, 于坐标系的变换, 如点(1,1)变到(2,3), 一者可以让坐标点移动, 二者可以让X轴单位度量长度变成原来1/2, 让Y轴单位度量长度变成原来1/3, 前后两者都可以达到目的。

6、 $Ma=b$ , 坐标点移动则是向量a经过矩阵M所描述的变换, 变成了向量b; 变坐标系则是有一个向量, 它在坐标系M的度量下结果为a, 在坐标系I (I为单位矩阵, 主对角为度量下结果为b, 本质上点运动与变换坐标系两者等价。为何? 如(5)所述, 同一个变换, 不同坐标系下表现不同矩阵, 但本质相同。

7、 $Ib$ , I在(6)中说为单位坐标系, 其实就是我们常说的直角坐标系, 如 $Ma=Ib$ , 在M坐标系里是向量a, 在I坐标系里是向量b, 本质上就是同一个向量, 故此谓矩阵乘法计算: 别。且慢, 什么是向量? 放在坐标系中度量, 后把度量的结果(向量在各个坐标轴上投影值)按顺序排列在一起, 即成向量。

8、b在I坐标系中则是 $Ib$ , a在M坐标系中则是 $Ma$ , 故而矩阵乘法 $M \times N$ , 不过是N在M坐标系中度量得到MN, 而M本身在I坐标系中度量出。故 $Ma=Ib$ , M坐标系中的a转过来右量, 却成了b。如向量(x,y)在单位长度均为1的直角坐标系中一量, 是(1,1), 而在X轴单位长度为2.Y轴单位长度为3一量则是(2,3)。

9、何谓逆矩阵?  $Ma=Ib$ , 之前已明了坐标点变换a->b等价于坐标系变换M->I, 但具体M如何变为I呢, 答曰让M乘以M的逆矩阵。以坐标系

×

👍41

💬24

📖

🔖

📱

⏪

⏩

为例，X轴单位度量长度变为原来的1/2，Y轴单位度量长度变为原来的1/3，即与矩阵

$$\begin{bmatrix} 1/2 & 0 \\ 0 & 1/3 \end{bmatrix}$$

相乘，便成直角坐标系l。即对坐标系施加变换，即让其与变换矩阵相乘。”

### 1.1 一堆基础概念

根据wikipedia的介绍，在矩阵中，n阶**单位矩阵**，是一个 $n \times n$ 的方形矩阵，其主对角线元素为1，其余元素为0。单位矩阵以 $I_n$ 表示；如果阶数n省略，或可由前后文得知，简记为 $I$ （或者E）。如下图所示，便是一些单位矩阵：

$$I_1 = [1], I_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, I_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \dots, I_n = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

单位矩阵中的第*i*列即为单位向量 $e_i$ 。单位向量同时也是单位矩阵的特征向量，特征值皆为1，因此这是唯一的特征值，且具有重数n。由此可见，单位矩阵的行列式为1，

**单位向量**又是什么呢？数学上，赋范向量空间中的单位向量就是长度为 1 的向量。欧几里得空间中，两个单位向量的点积就是它们之间角度的余弦（因为它们的长度都是一个非零向量 $\vec{u}$ 的正规化向量（即单位向量） $\hat{u}$ 就是平行于 $\vec{u}$ 的单位向量，记作：

$$\hat{u} = \frac{\vec{u}}{\|\vec{u}\|}$$

这里 $\|\vec{u}\|$ 是 $\vec{u}$ 的范数（长度）。  
何谓**点积**？点积又称内积，两个向量 $\vec{a} = [a_1, a_2, \dots, a_n]$ 和 $\vec{b} = [b_1, b_2, \dots, b_n]$ 的点积定义为：

$$\vec{a} \cdot \vec{b} = \sum_{i=1}^n a_i b_i = a_1 b_1 + a_2 b_2 + \dots + a_n b_n$$

这里的 $\sum$ 指示求和符号。  
例如，两个三维向量[1, 3, -5]和[4, -2, -1]的点积是：

$$\begin{bmatrix} 1 & 3 & -5 \end{bmatrix} \cdot \begin{bmatrix} 4 & -2 & -1 \end{bmatrix} = (1)(4) + (3)(-2) + (-5)(-1) = 3$$

$$\vec{a} \cdot \vec{b} = \vec{a}^T \vec{b}$$

👍41

💬24

📖

🔖

📱

<

>

这里的 $\vec{a}^T$  指示矩阵的转置。使用上面的例子， 将一个1×3矩阵（就是行向量） 乘以一个3×1向量得到结果(通过矩阵乘法的优势得到1×1矩阵也就一个数):

$$\begin{bmatrix} 1 & 3 & -5 \end{bmatrix} \begin{bmatrix} 4 \\ -2 \\ -1 \end{bmatrix} = \begin{bmatrix} 3 \end{bmatrix}$$

除了上面的代数定义外，点积还有另外一种定义：几何定义。在欧几里得空间中，点积可以直观地定义为：

$$\vec{a} \cdot \vec{b} = |\vec{a}| |\vec{b}| \cos \theta$$

这里 $|\vec{x}|$ 表示 $\vec{x}$ 的模（长度）， $\theta$ 表示两个向量之间的角度。 根据这个定义式可得：两个互相垂直的向量的点积总是零。若和都是单位向量（长度为1 积就是它们的夹角的余弦。

**正交**是垂直这一直观概念的推广，若内积空间中两向量的内积（即点积）为0，则称它们是正交的，相当于这两向量垂直，换言之，如果能够定义向 则正交可以直观的理解为垂直。而**正交矩阵**（orthogonal matrix）是一个元素为实数，而且行与列皆为正交的单位向量的方块矩阵（方块矩阵，或简 数及列数皆相同的矩阵。）

若数字 $\lambda$ 和非零向量 $\vec{v}$ 满足 $A\vec{v} = \lambda\vec{v}$ ，则 $\vec{v}$ 为 $A$ 的一个**特征向量**， $\lambda$ 是其对应的**特征值**。换句话说，在 $\vec{v}$ 这个方向上， $A$ 做的事情无非是把 $\vec{v}$ 沿其 $\vec{v}$ 的方向拉长/缩短了- 无规律的多维变换）， $\lambda$ 则是表示沿着这个方向上拉伸了多少的比例。简言之， $A$ 对 $\vec{v}$ 做了手脚，使得向量 $\vec{v}$ 变长或变短了，但 $\vec{v}$ 本身的方向不变。  
矩阵的**迹**是矩阵 $n \times n$ 的对角线元素之和，也是其 $n$ 个特征值之和。  
更多矩阵相关的概念可以查阅相关wikipedia，或《矩阵分析与应用》。


## 2 拉普拉斯矩阵

### 2.1 Laplacian matrix的定义

拉普拉斯矩阵（Laplacian matrix），也称为基尔霍夫矩阵, 是表示图的一种矩阵。给定一个有n个顶点的图 $G = (V, E)$ ，其拉普拉斯矩阵被定义为:

$$L = D - W$$

其中 $D$ 为图的度矩阵， $W$ 为图的邻接矩阵。  
举个例子。给定一个简单的图，如下：



把此“图”转换为**邻接矩阵**的形式，记为 $W$ ：

$$\begin{pmatrix} 0 & 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix}$$



41



24



把 $W$ 的每一列元素加起来得到 $N$ 个数，然后把它们放在对角线上（其它地方都是零），组成一个 $N \times N$ 的对角矩阵，记为**度矩阵** $D$ ，如下图

$$\begin{pmatrix} 2 & 0 & 0 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$

根据拉普拉斯矩阵的定义  $L = D - W$ ，可得拉普拉斯矩阵 $L$ 为：

$$\begin{pmatrix} 2 & -1 & 0 & 0 & -1 & 0 \\ -1 & 3 & -1 & 0 & -1 & 0 \\ 0 & -1 & 2 & -1 & 0 & 0 \\ 0 & 0 & -1 & 3 & -1 & -1 \\ -1 & -1 & 0 & -1 & 3 & 0 \\ 0 & 0 & 0 & -1 & 0 & 1 \end{pmatrix}$$

## 2.2 拉普拉斯矩阵的性质

介绍 拉普拉斯矩阵的性质之前，首先定义两个概念，如下：

①对于邻接矩阵，定义图中A子图与B子图之间所有边的权值之和如下：

$$W(A, B) := \sum_{i \in A, j \in B} w_{ij}$$

其中， $w_{ij}$ 定义为节点 $i$ 到节点 $j$ 的权值，如果两个节点不是相连的，权值为零。

②与某结点邻接的所有边的权值和定义为该顶点的度 $d$ ，多个 $d$  形成一个度矩阵 $D$ （对角阵）

$$d_i = \sum_{j=1}^n w_{ij}$$

41
24

- $L\mathbf{1} = \mathbf{0}$ ，即  $L$  的最小特征值是0，相应的特征向量是  $\mathbf{1}$ 。证明： $L^* \mathbf{1} = (D - W)^* \mathbf{1} = \mathbf{0} = \mathbf{0}^* \mathbf{1}$ 。（此外  $A\vec{v} = \lambda\vec{v}$ ，则  $\vec{v}$  为  $A$  的一个特征向量， $\lambda$  是其对应的特征值）。
- $L$  有  $n$  个非负实特征值  $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$
- 且对于任何一个属于实向量  $f \in \mathbb{R}^n$ ，有以下式子成立

$$f^T L f = \frac{1}{2} \sum_{i,j=1}^N w_{ij} (f_i - f_j)^2$$

其中， $L = D - W$ ， $d_i = \sum_{j=1}^n w_{ij}$ ， $W(A, B) := \sum_{i \in A, j \in B} w_{ij}$ 。

下面，来证明下上述结论，如下：

$$\begin{aligned} f^T L f &= f^T D f - f^T W f = \sum_{i=1}^n d_i f_i^2 - \sum_{i,j=1}^n f_i f_j w_{ij} \\ &= \frac{1}{2} \left( \sum_{i=1}^n d_i f_i^2 - 2 \sum_{i,j=1}^n f_i f_j w_{ij} + \sum_{j=1}^n d_j f_j^2 \right) = \frac{1}{2} \sum_{i,j=1}^n w_{ij} (f_i - f_j)^2 \end{aligned}$$

### 3 谱聚类

所谓聚类（Clustering），就是要把一堆样本合理地分成两份或者K份。从图论的角度来说，聚类的问题就相当于一个图的分割问题。即给定一个图  $G = (V, E)$ ，顶点集  $V$  表带权的边表示各个样本之间的相似度，谱聚类的目的便是要找到一种合理的分割图的方法，使得分割后形成若干个子图，连接不同子图的边的权重（相似度）尽可能低，同重（相似度）尽可能高。物以类聚，人以群分，相似的在一块儿，不相似的彼此远离。

至于如何把图的顶点集分割/切割为不相交的子图有多种办法，如

- 1. cut/Ratio Cut
- 2. Normalized Cut
- 3. 不基于图，而是转换成SVD能解的问题

目的是为了要让被割掉各边的权值和最小，因为被砍掉的边的权值和越小，代表被它们连接的子图之间的相似度越小，隔得越远，而相似度低的子图正好可以从中一刀切

本文重点阐述上述的第一种方法，简单提一下第二种，第三种本文不做解释，有兴趣的可以参考文献末的参考文献条目13。

#### 3.1 相关定义

为了更好的把谱聚类问题转换为图论问题，定义如下概念（有些概念之前已定义，权当回顾下）：

- 无向图  $G = (V, E)$ ，顶点集  $V$  表示各个样本，带权的边表示各个样本之间的相似度
- 与某结点邻接的所有边的权值和定义为该顶点的度  $d$ ，多个  $d$  形成一个度矩阵  $D$ （对角阵）

$$d_i = \sum_{j=1}^n w_{ij}$$

- 邻接矩阵  $W$ ， $A$  子图与  $B$  子图之间所有边的权值之和定义如下：

$$W(A, B) := \sum_{i \in A, j \in B} w_{ij}$$

其中， $w_{ij}$  定义为节点  $i$  到节点  $j$  的权值，如果两个节点不是相连的，权值为零。

- 相似度矩阵的定义。相似度矩阵由权值矩阵得到。实践中一般用高斯核函数（也称径向基函数核）计算相似度。距离越大，代表其相似度越小。

$$s(x_i, x_j) = e^{-\|x_i - x_j\|^2 / (2\sigma^2)}$$

41

24

子图A的指示向量如下：

$$\begin{aligned} \mathbb{1}_A &= (f_1, \dots, f_n)' \in \mathbb{R}^n \\ f_i &= 1 \text{ if } v_i \in A \\ f_i &= 0 \text{ otherwise} \end{aligned}$$

### 3.2 目标函数


因此，如何切割图则成为问题的关键。换言之，如何切割才能得到最优的结果呢？  
举个例子，如果用一张图片中的所有像素来组成一个图，并把（比如，颜色和位置上）相似的节点连接起来，边上的权值表示相似程度，现在要把图片分割为几个区域（要求是分割所得的 Cut 值最小，相当于那些被切断的边的权值之和最小，而权重比较大的边没有被切断。因为只有这样，才能让比较相似的点被保留在了同一个子图中，而大的点则被分割开了。

设  $A_1, \dots, A_k$  为图的几个子集（它们没有交集），为了让分割的 Cut 值最小，谱聚类便是要最小化下述目标函数：

$$\text{cut}(A_1, \dots, A_k) := \frac{1}{2} \sum_{i=1}^k W(A_i, \bar{A}_i)$$

其中k表示分成k个组， $A_i$ 表示第i个组， $\bar{A}_i$ 表示 $A_i$ 的补集， $W(A_i, \bar{A}_i)$ 表示第 $A_i$ 组与第 $\bar{A}_i$ 组之间的所有边的权重之和（换言之，如果要分成K个组，那么进行分割时去掉的边的权值的总和）。

为了让被切断边的权值之和最小，便是要让上述目标函数最小化。但很多时候，最小化 cut 通常会导致不好的分割。以分成2类为例，这个式子通常一个点和其余的n-1个点。如下图所示，很明显，最小化的smallest cut不是最好的cut，反而把{A、B、C、H}分为一边，{D、E、F、G}分为一边很合理 cut:



为了让每个类都有合理的大小，目标函数尽量让 $A_1, A_2 \dots A_k$  足够大。改进后的目标函数为：

$$\text{RatioCut}(A_1, \dots, A_k) := \frac{1}{2} \sum_{i=1}^k \frac{W(A_i, \bar{A}_i)}{|A_i|} = \sum_{i=1}^k \frac{\text{cut}(A_i, \bar{A}_i)}{|A_i|}$$

其中 $|A|$ 表示A组中包含的顶点数目。

或：

$$\text{Ncut}(A_1, \dots, A_k) := \frac{1}{2} \sum_{i=1}^k \frac{W(A_i, \bar{A}_i)}{\text{vol}(A_i)} = \sum_{i=1}^k \frac{\text{cut}(A_i, \bar{A}_i)}{\text{vol}(A_i)},$$

其中,  $\text{vol}(A) = \sum_{i \in A} w_{ij}$ .

### 3.3 最小化RatioCut 与最小化 $f'Lf$ 等价

下面，咱们来重点研究下**RatioCut** 函数。

目标函数： $\min_{A \subset V} \text{RatioCut}(A, \bar{A})$

定义向量  $f = (f_1, \dots, f_n)' \in \mathbb{R}^n$ ，且：

$$f_i = \begin{cases} \sqrt{|\bar{A}|/|A|} & \text{if } v_i \in A \\ -\sqrt{|A|/|\bar{A}|} & \text{if } v_i \in \bar{A} \end{cases}$$

根据之前得到的拉普拉斯矩阵矩阵的性质，已知

$$f'Lf = \frac{1}{2} \sum_{i,j=1}^N w_{ij}(f_i - f_j)^2$$

现在把 $f_i$ 的定义式代入上式，我们将得到一个非常有趣的结论！推导过程如下：

$$\begin{aligned} f'Lf &= \frac{1}{2} \sum_{i,j=1}^N w_{ij}(f_i - f_j)^2 \\ &= \frac{1}{2} \sum_{i \in A, j \in \bar{A}} w_{ij} \left( \sqrt{\frac{|\bar{A}|}{|A|}} + \sqrt{\frac{|A|}{|\bar{A}|}} \right)^2 + \sum_{i \in \bar{A}, j \in A} w_{ij} \left( -\sqrt{\frac{|\bar{A}|}{|A|}} + \sqrt{\frac{|A|}{|\bar{A}|}} \right)^2 \\ &= \text{cut}(A, \bar{A}) \left( \frac{|\bar{A}|}{|A|} + \frac{|A|}{|\bar{A}|} + 2 \right) \\ &= \text{cut}(A, \bar{A}) \left( \frac{|A| + |\bar{A}|}{|A|} + \frac{|A| + |\bar{A}|}{|\bar{A}|} \right) \\ &= |V| \cdot \text{RatioCut}(A, \bar{A}) \end{aligned}$$

41

24

<

>

是的，我们竟然从  $f'Lf$  推出了  $\text{RatioCut}$ ，换句话说，拉普拉斯矩阵  $L$  和我们要优化的目标函数  $\text{RatioCut}$  有着密切的联系。更准确的说，因为  $|V|$  是最小化  $\text{RatioCut}$ ，等价于最小化  $f'Lf$ 。

同时，因单位向量  $\mathbf{1}$  的各个元素全为1，所以直接展开可得到约束条件： $\|f\|^2 = \sum f_i^2 = n$  且  $f'\mathbf{1} = \sum f_i = 0$ ，具体推导过程如下：

$$\sum_{i=1}^n f_i = \sum_{i \in A} \sqrt{\frac{|\bar{A}|}{|A|}} - \sum_{i \in \bar{A}} \sqrt{\frac{|A|}{|\bar{A}|}} = |A| \sqrt{\frac{|\bar{A}|}{|A|}} - |\bar{A}| \sqrt{\frac{|A|}{|\bar{A}|}} = 0$$

$$\|f\|^2 = \sum_{i=1}^n f_i^2 = |A| \frac{|\bar{A}|}{|A|} + |\bar{A}| \frac{|A|}{|\bar{A}|} = |\bar{A}| + |A| = n$$

最终我们新的目标函数可以由之前的  $\min_{A \subset V} \text{RatioCut}(A, \bar{A})$ ，写成：

$$\min_{f \in \mathbb{R}^n} f'Lf \text{ subject to } f \perp \mathbf{1}, \|f\| = \sqrt{n}$$

其中， $f_i = \begin{cases} \sqrt{|\bar{A}|/|A|} & \text{if } v_i \in A \\ -\sqrt{|A|/|\bar{A}|} & \text{if } v_i \in \bar{A} \end{cases}$ ，且因  $\|f\| = \sqrt{n}$ ，所以有： $f'f = n$ （注： $f$ 是列向量的前提下， $f'f$ 是一个值，实数值， $ff'$ 是一个  $N \times N$  的矩阵）。

继续推导前，再次提醒特征向量和特征值的定义：

- 若数字  $\lambda$  和非零向量  $\vec{v}$  满足  $A\vec{v} = \lambda\vec{v}$ ，则  $\vec{v}$  为  $A$  的一个特征向量， $\lambda$  是其对应的特征值。

假定  $Lf = \lambda f$ ，此刻， $\lambda$  是特征值， $f$  是  $L$  的特征向量。两边同时左乘  $f'$ ，得到  $f'Lf = \lambda f'f$ ，而  $f'f = n$ ，其中  $n$  为图中顶点的数量之和，因此  $f'Lf =$  定值，所以要最小化  $f'Lf$ ，相当于就是要最小化  $\lambda$ 。因此，接下来，我们只要找到  $L$  的最小特征值  $\lambda$  及其对应的特征向量即可。

但到了这关键的最后一步，咱们却遇到了一个比较棘手的问题，即由之前得到的拉普拉斯矩阵的性质“ $L$  最小的特征值为零，并且对应的特征向量正交于  $\mathbf{1}$ ”的条件，因此，怎么办呢？根据论文“A Tutorial on Spectral Clustering”中所说的Rayleigh-Ritz 理论，我们可以取第2小的特征值的特征向量  $v$ 。

更进一步，由于实际中，特征向量  $v$  里的元素是连续的任意实数，所以可以根据  $v$  是大于0，还是小于0对应到离散情况下的  $f = (f_1, \dots, f_n)' \in \mathbb{R}^n$ ，决定  $f$  是取  $\sqrt{|\bar{A}|/|A|}$  还是  $-\sqrt{|A|/|\bar{A}|}$ 。因此，我们得到了一个离散化的特征向量  $f$ ，且  $f'f = n$ ，且  $f \perp \mathbf{1}$ ，所以  $f'Lf$  就是我们要最小化的  $\lambda$ 。



所以，问题就转换成了：求拉普拉斯矩阵的前K个特征值，再对前K个特征值对应的特征向量进行 K-means 聚类。而两类的，即将对应的特征向量排列起来，再进行 K-means聚类。两类分类和多类分类的问题，如出一辙。

就这样，因为离散求解  $f = (f_1, \dots, f_n)^T \in \mathbb{R}^n$  很困难，但 *RatioCut* 巧妙地把一个NP难度的问题转换成拉普拉斯矩阵特征值（向量）问题，将离散的特征向量，最小的系列特征向量对应着图最优的系列划分方法。剩下的仅是将松弛化的问题再离散化，即将特征向量再离散化，便可以得到性能不错的划分结果！

### 3.4 谱聚类算法过程

综上可得谱聚类的算法过程如下：

1. 根据数据构造一个Graph，Graph的每一个节点对应一个数据点，将各个点连接起来（随后将那些已经被连接起来但并不相似的点，通过 cut/RatioCut/NCut 的方式剪开），并且边的权重用于表示数据之间的相似度。把这个Graph用邻接矩阵的形式表示出来，记为  $W$ 。
2. 把  $W$  的每一列元素加起来得到  $N$  个数，把它们放在对角线上（其他地方都是零），组成一个  $N \times N$  的对角矩阵，记为度矩阵  $D$ 。并构造拉普拉斯矩阵  $L = D - W$ 。
3. 求出  $L$  的前  $k$  个特征值（前  $k$  个指按照特征值的大小从小到大排序得到） $\{\lambda_i\}_{i=1}^k$ ，以及对应的特征向量  $\{v_i\}_{i=1}^k$ 。
4. 把这  $k$  个特征（列）向量排列在一起组成一个  $N \times k$  的矩阵，将其中每一行看作  $k$  维空间中的一个向量，并使用 K-means 算法进行聚类。聚类的结果所属的类别就是原来 Graph 中的节点亦即最初的  $N$  个数据点分别所属的类别。

或许你已经看出来，谱聚类的基本思想便是利用样本数据之间的相似矩阵（拉普拉斯矩阵）进行特征分解（通过 Laplacian Eigenmap 的降维方式降维），将得到的特征向量进行 K-means 聚类。

此外，谱聚类和传统的聚类方法（例如 K-means）相比，谱聚类只需要数据之间的相似度矩阵就可以了，而不必像 K-means 那样要求数据必须是  $N$  维空间中的向量。

### 4 参考文献与推荐阅读

1. 孟岩之理解矩阵系列：<http://blog.csdn.net/myan/article/details/1865397>;
2. 理解矩阵的12点数学笔记：<http://www.51weixue.com/thread-476-1-1.html>;
3. 一堆wikipedia，比如特征向量：<https://zh.wikipedia.org/wiki/%E7%89%B9%E5%BE%81%E5%90%91%E9%87%8F>;
4. wikipedia上关于拉普拉斯矩阵的介绍：[http://en.wikipedia.org/wiki/Laplacian\\_matrix](http://en.wikipedia.org/wiki/Laplacian_matrix);
5. 邹博之聚类PPT：<http://pan.baidu.com/s/1i3gOYJr>;
6. 关于谱聚类的一篇非常不错的英文文献，“A Tutorial on Spectral Clustering”：[http://engr.case.edu/ray\\_soumya/mlrg/Luxburg07\\_tutorial\\_spectral\\_clustering.pdf](http://engr.case.edu/ray_soumya/mlrg/Luxburg07_tutorial_spectral_clustering.pdf);
7. 知乎上关于矩阵和特征值的两个讨论：<http://www.zhihu.com/question/21082351>，<http://www.zhihu.com/question/21874816>;
8. 谱聚类：<http://www.cnblogs.com/fengyan/archive/2012/06/21/2553999.html>;
9. 谱聚类算法：<http://www.cnblogs.com/sparkwen/p/3155850.html>;
10. 漫谈 Clustering 系列：[http://blog.pluskid.org/?page\\_id=78](http://blog.pluskid.org/?page_id=78);
11. 《Mining of Massive Datasets》第10章：<http://infolab.stanford.edu/~ullman/mmds/book.pdf>;
12. Tydsh: Spectral Clustering: ①[http://blog.sina.com.cn/s/blog\\_53a8a4710100g2rt.html](http://blog.sina.com.cn/s/blog_53a8a4710100g2rt.html), ②[http://blog.sina.com.cn/s/blog\\_53a8a4710100g2rv.html](http://blog.sina.com.cn/s/blog_53a8a4710100g2rv.html), ③[http://blog.sina.com.cn/s/blog\\_53a8a4710100g2ry.html](http://blog.sina.com.cn/s/blog_53a8a4710100g2ry.html), ④[http://blog.sina.com.cn/s/blog\\_53a8a4710100g2rz.html](http://blog.sina.com.cn/s/blog_53a8a4710100g2rz.html);
13. H. Zha, C. Ding, M. Gu, X. He, and H.D. Simon. Spectral relaxation for K-means clustering. Advances in Neural Information Processing (NIPS 2001). pp. 1057-1064, Vancouver, Canada. Dec. 2001;
14. 机器学习中谱聚类方法的研究：<http://lamda.nju.edu.cn/conf/MLA07/files/YuJ.pdf>;
15. 谱聚类的算法实现：<http://liuzhiqiangucruc.iteye.com/blog/2117144>。

拉普拉斯矩阵及谱聚类

阅读量 7162

拉普拉斯矩阵及谱聚类(Laplacian Matrix and Spectral Clustering)与相似性度量相关的论文中经常出现... 博文 来自: zhoutongchi...

想对作者说点什么

王小懒ws: 谢谢分享 (4个月前 #19楼)